TÍTULO PROYECTO: Predicción del precio por noche de alojamientos de Airbnb en Nueva York (2019)

INTEGRANTES: Ismael López Cardozo – Tatiana Fernanda Suarez

1. ENTENDIMIENTO DEL NEGOCIO

1.1 DESCRIPCIÓN DEL NEGOCIO

Airbnb es una plataforma digital de alquiler de alojamientos de corta estancia que conecta a **anfitriones**, que publican casas, apartamentos o habitaciones, con **huéspedes** que los reservan por noches. Airbnb cobra una comisión por cada reserva, y el anfitrión fija libremente el precio por noche de su anuncio.

Nueva York es uno de los mercados más grandes de la plataforma: en 2019 contaba con cerca de 49 000 anuncios activos, distribuidos en los cinco distritos de la ciudad (Manhattan, Brooklyn, Queens, Bronx y Staten Island). La mayoría se concentran en Manhattan (44 %) y Brooklyn (41 %), y se reparten casi por igual entre viviendas completas (52 %) y habitaciones privadas (46 %).

1.2 DESCRIPCIÓN DEL PROBLEMA

Los precios del mercado son muy dispersos: van de 10 a 10 000 USD por noche, con una mediana de 106 USD. Para un anfitrión, en especial uno nuevo, no es fácil decidir cuánto cobrar: un precio demasiado alto reduce la ocupación y uno demasiado bajo deja de percibir ingresos. Tampoco es evidente cuánto influyen en el precio la ubicación, el tipo de alojamiento o las condiciones de reserva.

Problema: no existe una forma objetiva de estimar un precio de referencia para un alojamiento a partir de sus características. **Pregunta de minería:** ¿es posible predecir el precio por noche de un anuncio de Airbnb en Nueva York a partir de su ubicación, tipo de alojamiento, condiciones de reserva y actividad del anfitrión?

1.3 OBJETIVOS DE LA MINERÍA

- Desarrollar un **modelo predictivo de regresión** para estimar el precio por noche de un alojamiento de Airbnb en Nueva York, mediante métodos de aprendizaje supervisado y de ensamble, a partir de su ubicación, tipo de alojamiento, condiciones de reserva y actividad del anfitrión.
- Desplegar el mejor modelo en una **aplicación web con interfaz gráfica (Streamlit)** que permita a un anfitrión obtener el precio estimado de su alojamiento.

1.4 DISEÑO DE SOLUCIÓN

Descripción del Problema	Tipo de análisis (Predictivo/ Descriptivo)	Tipo de aprendizaje	Tarea analítica	Requerimiento en los datos	Métodos	Evaluación
Estimar el precio por noche de un alojamiento de Airbnb en Nueva York	Predictivo	Supervisado	Regresión	Datos históricos etiquetados con el precio (variable objetivo numérica) y variables de ubicación, tipo de alojamiento, reservas y anfitrión	Ridge, KNN, árbol de decisión, red neuronal MLP. Ensambles: Random Forest, Gradient Boosting, XGBoost. Validación: división 70/30 y validación cruzada de 10 pliegues Comparación de modelos: ANOVA y Tukey	Medidas de calidad: R^2, MSE, RMSE, MAE, MedAE, MAPE y error máximo.

1.5 VALOR ESPERADO DE LA EVALUACIÓN (Línea base)

Como **línea base** se usa un modelo ingenuo que predice siempre la mediana del precio del conjunto de entrenamiento (107 USD). Evaluado sobre el 30 % de prueba obtiene: **MAE = 85.2 USD**, **MedAE = 47.0 USD**, **MAPE = 57.8 %** y **R^2 (escala logarítmica) ≈ 0**.

Valor esperado: que el modelo final reduzca el MAE al menos un 25 % respecto a la línea base (MAE ≤ 64 USD) y explique al menos el 50 % de la variabilidad del logaritmo del precio (R^2 log ≥ 0.50). Estos criterios se cumplieron (ver sección 4.3).

1.6 RECURSOS HW Y SW (creacion de modelos y para el despliegue)

Creación de modelos

- **Hardware:** Google Colab, entorno gratuito con CPU (2 núcleos virtuales) y unos 12 GB de RAM; no se requiere GPU. El notebook de modelado se ejecuta en unos 30 minutos.
- **Software:** Python 3; pandas y NumPy (manipulación de datos); Matplotlib y seaborn (gráficas); ydata-profiling (perfilado); scikit-learn (modelos, pipelines, validación cruzada, GridSearchCV); XGBoost; Optuna (optimización bayesiana); SciPy y statsmodels (ANOVA y Tukey); joblib (almacenamiento del modelo).

Despliegue

- **Software:** Streamlit (interfaz gráfica), folium y streamlit-folium (mapa interactivo para seleccionar la ubicación), GitHub (repositorio con los archivos de la aplicación) y Streamlit Community Cloud (publicación de la aplicación en un enlace web). En requirements.txt, las versiones de scikit-learn y XGBoost se fijan iguales a las del entorno de entrenamiento, y en Streamlit Cloud se usa la misma versión de Python.
- **Hardware:** servidores de Streamlit Community Cloud (gratuito); no se requiere infraestructura propia. El modelo ocupa unos 17 MB.

2. ENTENDIMIENTO DE LOS DATOS ESPECÍFICOS (TI)

2.1 CICLO DE LOS DATOS: Generación, Almacenamiento, Modificación, Periodicidad

- **Generación:** los datos se generan en la plataforma Airbnb: los anfitriones crean y editan sus anuncios (ubicación, tipo, precio, noches mínimas, disponibilidad) y los huéspedes dejan

reseñas tras su estadía. El proyecto Inside Airbnb recopila esta información pública del sitio web mediante extracción automática (web scraping).

- **Almacenamiento:** el conjunto se distribuye como un único archivo CSV, AB_NYC_2019.csv (48 895 registros, 16 variables, unos 7 MB), publicado en Kaggle a partir de Inside Airbnb. En el proyecto se almacena en el entorno de Google Colab.
- **Modificación:** en la plataforma, los anfitriones pueden cambiar el precio y la disponibilidad en cualquier momento, y las reseñas se acumulan con el tiempo. El archivo es una fotografía estática del mercado a julio de 2019 (la reseña más reciente es del 8 de julio de 2019).
- **Periodicidad:** Inside Airbnb publica nuevas extracciones de forma periódica. Para este proyecto se usa una única extracción (2019); para mantener el modelo vigente habría que reentrenarlo con extracciones recientes (ver sección 5).

2.2 DICCIONARIO DE DATOS

Tabla 1. Diccionario de datos del archivo AB_NYC_2019.csv

Variable	Tipo	Descripción
id	Numérica entera (código)	Identificador único del anuncio
name	Texto	Nombre o título del anuncio
host_id	Numérica entera (código)	Identificador del anfitrión
host_name	Texto	Nombre del anfitrión
neighbourhood_group	Categórica (5)	Distrito: Manhattan, Brooklyn, Queens, Bronx, Staten Island
neighbourhood	Categórica (221)	Barrio en el que se ubica el alojamiento
latitude	Numérica continua	Latitud del alojamiento (grados)
longitude	Numérica continua	Longitud del alojamiento (grados)
room_type	Categórica (3)	Tipo de alojamiento: Entire home/apt, Private room, Shared room
price	Numérica entera (USD)	Precio por noche. Variable objetivo
minimum_nights	Numérica entera	Número mínimo de noches por reserva
number_of_reviews	Numérica entera	Número total de reseñas recibidas
last_review	Fecha	Fecha de la reseña más reciente
reviews_per_month	Numérica continua	Promedio de reseñas por mes
calculated_host_listings_count	Numérica entera	Número de anuncios que tiene el anfitrión en la plataforma
availability_365	Numérica entera	Días del año en que el alojamiento está disponible para reservar (0–365)

2.3 REGLAS DE CALIDAD

Tabla 2. Reglas de calidad definidas desde el negocio

Variable	Regla de calidad (negocio)
id	Único y no nulo
neighbourhood_group	Manhattan, Brooklyn, Queens, Bronx, Staten Island
room_type	Entire home/apt, Private room, Shared room
latitude	40.49 – 40.92 (límites de la ciudad de Nueva York)
longitude	−74.26 – −73.70 (límites de la ciudad de Nueva York)
price	Mayor que 0 USD
minimum_nights	1 – 365 noches
number_of_reviews	Entero mayor o igual a 0
reviews_per_month	Mayor o igual a 0; igual a 0 si number_of_reviews = 0
calculated_host_listings_count	Entero mayor o igual a 1
availability_365	0 – 365 días
last_review	Fecha anterior o igual a la fecha de extracción (julio de 2019)

3. PREPARACIÓN DE DATOS

3.1 INTEGRACIÓN

Los datos provienen de una única fuente, el archivo AB_NYC_2019.csv, que se cargó con pandas: **48 895 registros y 16 variables**. No fue necesario integrar varias fuentes. Se verificó que no hay identificadores (id) repetidos y las variables de texto se convirtieron al tipo categórico.

3.2 SELECCIÓN DE VARIABLES

- **Variables irrelevantes eliminadas:** id y host_id (códigos), name y host_name (texto libre y nombres de personas). No aportan información generalizable sobre el precio.
- **Variable redundante eliminada:** neighbourhood. El barrio queda determinado por las coordenadas (latitude y longitude) y su agrupación general se conserva en neighbourhood_group. Además, su alta cardinalidad (221 categorías) generaría demasiadas variables al codificarla.

Quedan 11 variables: neighbourhood_group, latitude, longitude, room_type, price, minimum_nights, number_of_reviews, last_review, reviews_per_month, calculated_host_listings_count y availability_365.

3.3 DESCRIPCIÓN ESTADÍSTICA

Tabla 3. Descripción estadística de las variables numéricas (48 895 registros)

Variable	Media	Mediana	Desv. estándar	Mínimo	Máximo
price (USD)	152.72	106.00	240.15	0	10 000
minimum_nights	7.03	3.00	20.51	1	1 250
number_of_reviews	23.27	5.00	44.55	0	629
reviews_per_month	1.37	0.72	1.68	0.01	58.50
calculated_host_listings_count	7.14	1.00	32.95	1	327
availability_365	112.78	45.00	131.62	0	365
latitude	40.73	40.72	0.05	40.50	40.91
longitude	−73.95	−73.96	0.05	−74.24	−73.71

- **price** es muy asimétrica: la media (152.7 USD) es mucho mayor que la mediana (106 USD) y el máximo llega a 10 000 USD. También son asimétricas minimum_nights, number_of_reviews y calculated_host_listings_count: la mayoría de los valores son bajos, con pocos valores muy altos.
- **availability_365:** la mitad de los anuncios están disponibles 45 días o menos al año, y muchos tienen 0 días disponibles.
- **Categóricas:** Manhattan (44.3 %) y Brooklyn (41.1 %) concentran la mayoría de los anuncios, seguidos de Queens (11.6 %), Bronx (2.2 %) y Staten Island (0.8 %). Por tipo, predominan las viviendas completas (52.0 %) y las habitaciones privadas (45.7 %); las compartidas son el 2.4 %.
- **last_review:** las reseñas más recientes van de 2011 a julio de 2019, con la mayoría en 2019.

3.4 LIMPIEZA DE ATÍPICOS- ERRORES

Se comparan los valores observados con las reglas de calidad de la Tabla 2. Solo se eliminan los valores que son **errores**. Los valores atípicos legítimos (por ejemplo, alojamientos de lujo con precios de miles de dólares) se conservan, porque representan fenómenos reales del mercado y eliminarlos haría que el modelo ignorara ese segmento.

Variable	Regla de calidad	Mínimo-Máximo/ categorías de los datos	Indicativo de error
price	> 0 USD	0 – 10 000	Error: 11 registros con precio 0 (eliminados). Precios altos: reales, se conservan
minimum_nights	1 – 365	1 – 1 250	Error: 14 registros con más de 365 noches (eliminados)
latitude	40.49 – 40.92	40.50 – 40.91	Sin error
longitude	−74.26 – −73.70	−74.24 – −73.71	Sin error
number_of_reviews	≥ 0	0 – 629	Sin error
reviews_per_month	≥ 0	0.01 – 58.50	Sin error
calculated_host_listings_count	≥ 1	1 – 327	Sin error
availability_365	0 – 365	0 – 365	Sin error
neighbourhood_group	5 distritos	5 distritos	Sin error
room_type	3 tipos	3 tipos	Sin error

Se eliminaron 25 registros con errores; el conjunto queda con **48 870 registros**.

3.5 LIMPIEZA DE NULOS

La estrategia en la limpieza de nulos es la siguiente:

- Eliminar los registros con más del 15% de valores faltantes.
- Eliminar las variables con más del 15% de valores faltantes.
- Imputar variables con máximo 15% de valores faltantes: llenar los campos con la media (numérica simétrica), mediana (numérica asimétrica), moda (categórica).

En la siguiente tabla se reportan las acciones realizadas:

Variable	Limpieza de nulos
reviews_per_month	10 043 nulos (20.5 %). Imputada con 0: son nulos estructurales, que coinciden exactamente con los anuncios sin reseñas (number_of_reviews = 0). El valor real se conoce con certeza (0 reseñas por mes), por lo que no aplica el límite del 15 %.
last_review	10 043 nulos (20.5 %). Eliminada por superar el 15 % de nulos; además, al ser una fecha, no existe un valor de imputación con sentido para un anuncio sin reseñas.
name, host_name	16 y 21 nulos. No requieren tratamiento: ya se habían eliminado como variables irrelevantes.
Demás variables	Sin valores nulos.

Después de la limpieza, el conjunto no tiene valores nulos: **48 870 registros y 10 variables**.

3.6 ANÁLISIS DE CORRELACIONES PARA REDUNDANCIA

Se calculó la matriz de correlación de Pearson entre todas las variables (las categóricas, convertidas en variables dummy). Se considera redundante un par de variables distintas con correlación absoluta mayor que 0.8. Las correlaciones más altas fueron:

Tabla 4. Correlaciones más altas entre variables

Par de variables	Correlación |r|	Interpretación
room_type_Private room – room_type_Entire home/apt	0.95	Dummies de la misma variable; son complementarias, no redundantes
neighbourhood_group_Brooklyn – neighbourhood_group_Manhattan	0.75	Dummies de la misma variable
latitude – neighbourhood_group_Brooklyn	0.67	Relación esperada (el distrito depende de la ubicación); < 0.8
longitude – neighbourhood_group_Queens	0.62	Relación esperada; < 0.8
number_of_reviews – reviews_per_month	0.59	Relación moderada; < 0.8

Ningún par de variables distintas supera el umbral, por lo que **no se elimina ninguna variable por redundancia**.

3.7 ANÁLISIS DE CORRELACIONES PARA IRRELEVANCIA (PREDICCIONES)

Se buscan variables con correlación muy baja con el precio ($|r| < 0.05$). Como la correlación de Pearson solo mide relaciones lineales y es muy sensible a los valores extremos del precio, se verificó también la correlación de Spearman, basada en rangos. Para las categóricas se calculó el promedio ponderado de la correlación absoluta de sus dummies.

Tabla 5. Correlación de cada variable con el precio

Variable	Pearson	Spearman	Decisión
latitude	0.034	0.136	Se conserva
longitude	−0.150	−0.438	Se conserva
minimum_nights	0.054	0.101	Se conserva
number_of_reviews	−0.048	−0.055	Se conserva
reviews_per_month	−0.051	−0.060	Se conserva
calculated_host_listings_count	0.057	−0.106	Se conserva
availability_365	0.082	0.086	Se conserva
neighbourhood_group (ponderada)	0.123	—	Se conserva
room_type (ponderada)	0.244	—	Se conserva

- **latitude** tiene una correlación de Pearson baja (0.03), pero no se elimina: su correlación de Spearman es mayor (0.14) y su efecto sobre el precio no es lineal, sino que depende de su combinación con la longitud (cercanía al centro de Manhattan). Ambas coordenadas se conservan y se transforman en la ingeniería de características.
- **number_of_reviews** tiene Pearson en el límite (−0.048), pero con Spearman supera el umbral (−0.055), al igual que las demás variables.

En consecuencia, **no se elimina ninguna variable por irrelevancia**. El conjunto preparado (Airbnb_NYC_2019_limpio.csv) tiene 48 870 registros y 10 variables.

3.8 INGENIERÍA DE CARACTERÍSTICAS

3.8.1 BALANCEO (CLASIFICACIÓN)

El balanceo se aplica en problemas de clasificación con clases desiguales. Este es un problema de **regresión** (price es numérica continua), por lo que no hay clases que balancear y **el balanceo no aplica**. El problema equivalente, la asimetría del precio, se trata con la transformación logarítmica.

3.8.2 CREACIÓN DE NUEVAS VARIABLES

Se creó la variable **dist_centro_km**: la distancia en kilómetros desde el alojamiento hasta Times Square (40.7580, −73.9855), calculada con la fórmula de haversine a partir de latitude y longitude. Resume en una sola variable el efecto de la ubicación, que las coordenadas por separado no muestran de forma lineal.

Su correlación de Spearman con el precio es **−0.46**: cuanto más lejos del centro, más barato el alojamiento. Es mucho más fuerte, en valor absoluto, que la de latitude (0.14) o longitude (−0.44) por separado. Se conservan también las coordenadas, que los modelos de árboles aprovechan para identificar zonas.

3.8.3 REDUCCIÓN DE DIMENSIÓN (OPCIONAL EN PREDICCIONES)

No se aplicó. Después de la codificación el modelo trabaja con solo 16 características para 34 209 registros de entrenamiento, por lo que no hay problema de alta dimensionalidad, y conservar las variables originales mantiene la interpretabilidad del modelo.

3.8.4 TRANSFORMACIONES

- **Logaritmo del precio (variable objetivo):** los modelos se entrenan con log(1 + price) y la predicción se devuelve a dólares con la transformación inversa. La asimetría pasa de 18.1 a 0.61, y los precios extremos dejan de dominar el entrenamiento.
- **Logaritmo de los conteos:** log(1 + x) en minimum_nights, number_of_reviews, reviews_per_month y calculated_host_listings_count, por ser muy asimétricas.
- **Codificación one-hot** de neighbourhood_group y room_type.
- **Estandarización** (media 0, desviación 1) de las variables numéricas, necesaria para KNN, la red neuronal y la regresión Ridge.

Todas las transformaciones están dentro de un pipeline de scikit-learn, de modo que en cada pliegue de la validación cruzada se ajustan solo con los datos de entrenamiento y no hay fuga de información.

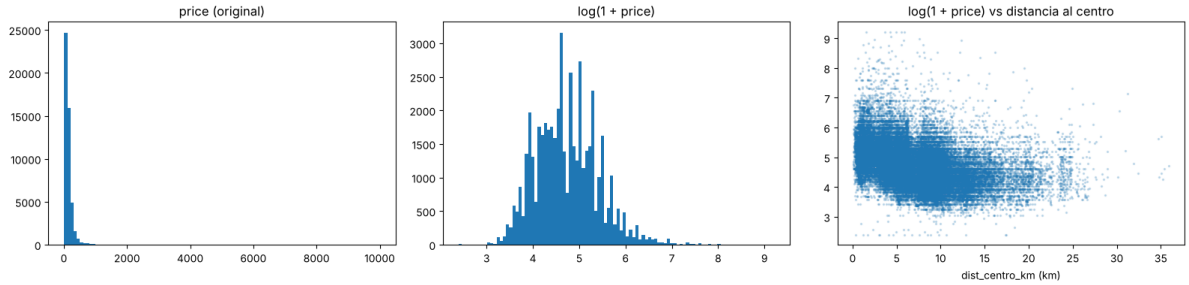


Figura 1. Distribución del precio original, de log(1 + price) y relación con la distancia al centro

4. MODELAMIENTO, EVALUACIÓN E INTERPRETACIÓN

4.1 CONFIGURACIÓN MÉTODOS DE MACHINE LEARNING (se aplican varios métodos)

Los datos se dividieron en **70 % de entrenamiento** (34 209 registros) y **30 % de prueba** (14 661 registros), con semilla 42. Con el 70 % se aplicó **validación cruzada de 10 pliegues** (K-Fold con mezcla aleatoria). La validación cruzada no es una medida de evaluación, sino la **técnica de validación**: divide el 70 % en 10 partes, entrena cada modelo 10 veces con 9 partes y lo evalúa con la parte restante; en cada repetición se calculan las medidas de calidad (sección 4.2). Así se obtienen 10 valores de cada medida por modelo, que permiten estimar el desempeño esperado y aplicar ANOVA y Tukey. Se usaron 4 métodos de aprendizaje supervisado y 3 métodos de ensamble, todos dentro del mismo pipeline de preparación:

Método de IA	Configuración de parámetros
Regresión Ridge	alpha = 1.0 (regularización L2)
K vecinos más cercanos (KNN)	n_neighbors = 15, pesos uniformes, distancia euclidiana
Árbol de decisión	max_depth = 10, min_samples_leaf = 20
Red neuronal (MLP)	2 capas ocultas (64 y 32 neuronas), activación ReLU, optimizador Adam, early_stopping, max_iter = 300
Random Forest (ensamble – bagging)	100 árboles, min_samples_leaf = 5
Gradient Boosting (ensamble – boosting)	100 árboles, learning_rate = 0.1, max_depth = 3
XGBoost (ensamble – boosting)	300 árboles, learning_rate = 0.05, max_depth = 6

4.2 ANALISIS DE MEDIDAS DE CALIDAD

Para cada modelo se calcularon 8 medidas de calidad en los 10 pliegues de la validación cruzada. La tabla muestra el promedio, ordenado de mejor a peor MAE. El tiempo de aprendizaje es el total de los 10 pliegues.

Método	R^2 log	R^2 USD	MSE (USD^2)	RMSE (USD)	MAE (USD)	MedAE (USD)	MAPE	Error máx. (USD)	Tiempo (s)
XGBoost	0.610	0.200	43 266	202.31	55.95	23.83	0.319	6 234	6.9
Random Forest	0.602	0.186	44 097	204.18	56.32	24.23	0.322	6 304	61.3
Gradient Boosting	0.583	0.151	45 776	208.38	58.13	25.09	0.330	6 365	51.3
KNN	0.566	0.154	45 601	207.94	58.57	25.24	0.338	6 403	2.8
Red neuronal (MLP)	0.574	0.150	45 757	208.40	58.69	25.14	0.334	6 374	41.7
Árbol de decisión	0.556	0.153	45 626	208.02	59.62	25.51	0.346	6 380	2.1
Regresión Ridge	0.526	0.124	46 985	211.36	61.06	27.48	0.355	6 414	1.1

Interpretación de las medidas

- **R^2 en escala logarítmica (0.53 – 0.61):** el mejor modelo explica cerca del 61 % de la variabilidad del logaritmo del precio, la escala en la que aprende. Es un valor razonable, porque el conjunto no incluye variables decisivas como el tamaño, el número de habitaciones o la calidad del alojamiento.
- **R^2 en dólares (0.12 – 0.20):** es mucho más bajo porque en dólares está dominado por unos pocos alojamientos de miles de dólares que ningún modelo puede anticipar con estas variables: un solo error de 9 000 USD pesa más que miles de errores pequeños.
- **MSE (43 266 – 46 985 USD^2):** promedio de los errores al cuadrado. Al estar en dólares al cuadrado no se interpreta directamente (su raíz es el RMSE); como eleva cada error al cuadrado, está dominado por los pocos errores muy grandes.
- **MAE (55.9 – 61.1 USD):** en promedio, la predicción del mejor modelo se aleja unos 56 USD del precio real.
- **RMSE (202 – 211 USD):** es unas 3.6 veces el MAE; como eleva los errores al cuadrado, confirma que hay pocos errores muy grandes, los de los precios extremos.
- **MedAE (23.8 – 27.5 USD):** para la mitad de los alojamientos el error es menor que unos 24 USD; es la medida que mejor describe el error en un alojamiento típico.
- **MAPE (0.319 – 0.355):** en promedio, el error equivale al 32 % – 36 % del precio, cerca de un tercio.
- **Error máximo (6 234 – 6 414 USD, promedio de los 10 pliegues):** en cada pliegue, el peor error corresponde a un alojamiento de miles de dólares que el modelo predice como uno normal. Es casi igual en los 7 modelos porque ninguno puede anticipar esos precios extremos con las variables disponibles.
- **Tiempo de aprendizaje:** XGBoost es a la vez el más preciso y uno de los más rápidos (6.9 s); Random Forest, Gradient Boosting y la red neuronal son los más lentos.

XGBoost y Random Forest son los mejores en las 8 medidas; Gradient Boosting, KNN y la red neuronal tienen resultados muy parecidos entre sí; la regresión Ridge es la peor en todas, lo que indica que la relación entre las variables y el precio no es lineal.

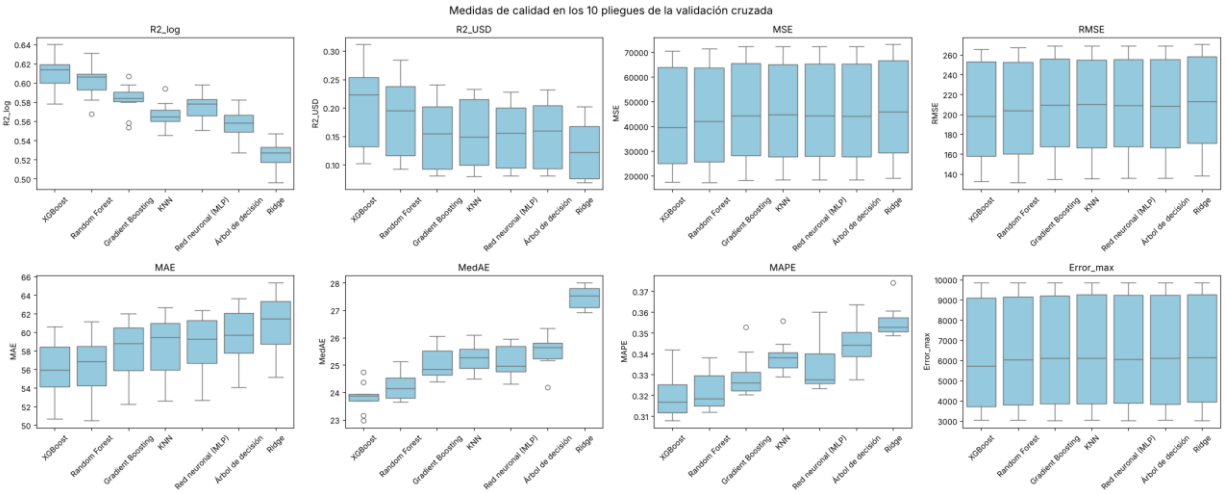


Figura 2. Medidas de calidad en los 10 pliegues de la validación cruzada

4.3 SELECCIÓN DEL MEJOR MODELO

Criterio de selección. El mejor modelo se selecciona por el **menor MAE** (error en dólares, fácil de interpretar y no dominado por los precios extremos) en tres etapas: (1) selección de los 3 mejores modelos con ANOVA y Tukey; (2) hiperparametrización de esos 3 modelos con GridSearch y optimización bayesiana; (3) confirmación con el 30 % de prueba.

Etapa 1 – ANOVA y Tukey. Se compararon los MAE de los 10 pliegues de los 7 modelos ($\alpha = 0.05$).

- **ANOVA de un factor:** $F = 3.19$, p-valor $= 0.0086 < 0.05$. Se rechaza la hipótesis nula: no todos los modelos tienen el mismo MAE medio.
- **Tukey (HSD):** de las 21 comparaciones por pares, solo 2 son significativas: XGBoost vs. Ridge (diferencia de 5.1 USD, $p = 0.010$) y Random Forest vs. Ridge (4.7 USD, $p = 0.022$). Las demás diferencias (0.1 a 3.7 USD) no son significativas.
- **Modelos seleccionados:** XGBoost y Random Forest, con el menor MAE y únicos significativamente mejores que el modelo lineal; y Gradient Boosting, tercero en MAE (58.1 USD). Su diferencia con KNN y la red neuronal no es significativa; se eligió por tener el mejor MAE y el mejor R^2 logarítmico de ese grupo y por ser el que más podía mejorar con la hiperparametrización (usaba su configuración por defecto).

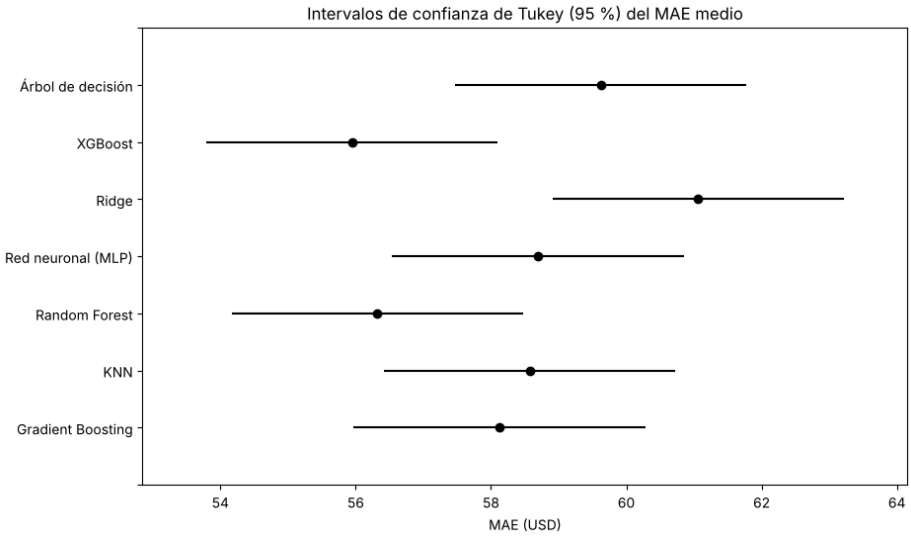


Figura 3. Intervalos de confianza de Tukey (95 %) del MAE medio de cada modelo

Etapa 2 – Hiperparametrización. Cada modelo se optimizó con GridSearchCV (rejilla de 4 a 8 combinaciones) y con optimización bayesiana (Optuna, algoritmo TPE, 20 intentos), ambas con validación cruzada de 3 pliegues sobre el 70 %. **Etapa 3:** los 6 modelos resultantes se evaluaron con el 30 % de prueba.

Tabla 6. Resultados de la hiperparametrización: MAE estimado con validación cruzada y medidas sobre el 30 % de prueba (errores en USD; MSE en USD²)

Modelo	Técnica	MAE (valid. cruzada)	MSE	RMSE	MAE	MedAE	MAPE	Error máx.	R^2 log
XGBoost	Bayesiana (Optuna)	55.77	60 245	245.45	56.92	22.97	0.310	9 949	0.621
XGBoost	GridSearch	55.96	60 382	245.73	57.17	23.29	0.312	9 953	0.617
Random Forest	Bayesiana (Optuna)	56.21	60 909	246.80	57.38	23.53	0.312	9 952	0.613
Random Forest	GridSearch	56.47	61 583	248.16	57.68	23.83	0.314	9 951	0.610
Gradient Boosting	Bayesiana (Optuna)	56.56	60 868	246.71	57.71	23.66	0.315	9 944	0.612
Gradient Boosting	GridSearch	56.84	61 348	247.69	58.07	23.70	0.317	9 947	0.606

- La optimización bayesiana superó a GridSearch en los 3 modelos, porque explora valores continuos y concentra los intentos en las zonas más prometedoras.
- Gradient Boosting fue el que más mejoró (MAE de 58.1 a 56.6 USD); XGBoost y Random Forest mejoraron menos porque su configuración inicial ya era buena.
- El orden se mantiene en la prueba y el MAE de prueba (56.9 USD) es casi igual al estimado con validación cruzada (55.8 USD): **no hay sobreajuste**.

Mejor modelo: XGBoost optimizado con optimización bayesiana (Optuna).

Método de IA	Configuración de parámetros final
XGBoost (XGBRegressor), dentro del pipeline de preparación y con objetivo log(1 + price)	n_estimators = 778 learning_rate = 0.0153 max_depth = 9 subsample = 0.66 colsample_bytree = 0.79 min_child_weight = 1

Evaluación final con el 30 % de prueba: R^2 log = 0.621, R^2 USD = 0.135, MSE = 60 244.81 USD², RMSE = 245.45 USD, MAE = 56.92 USD, MedAE = 22.97 USD, MAPE = 0.310 y error máximo = 9 948.72 USD. Frente a la línea base (MSE = 71 842.37 USD², RMSE = 268.03 USD, MAE = 85.16 USD, MedAE = 47.0 USD, MAPE = 0.578), el modelo **reduce el MAE un 33 %** y el error mediano a la mitad, y cumple el valor esperado definido en la sección 1.5.

- El R^2 en dólares (0.135), el MSE y el RMSE (245 USD) son peores que los estimados con validación cruzada porque la prueba contiene 10 alojamientos de 5 000 USD o más, que dominan las medidas basadas en errores al cuadrado. Las medidas robustas (MAE, MedAE, MAPE y R^2 log) se mantienen estables.
- **Error máximo (9 949 USD):** corresponde al alojamiento de 10 000 USD por noche del conjunto de prueba, al que el modelo asigna un precio normal (unos 51 USD). Es un caso aislado: el 96 % de las predicciones tiene un error menor de 200 USD. La línea base tiene un error máximo similar (9 893 USD), porque ningún modelo con estas variables puede anticipar ese caso.
- **En la práctica:** para un alojamiento típico el modelo se equivoca unos 23 USD. Sirve como precio de referencia para alojamientos comunes, pero no para el segmento de lujo, cuyos precios dependen de variables que el conjunto no incluye.
- **Variables más importantes:** el tipo de alojamiento (vivienda completa ≈ 0.58 de la importancia), estar en Manhattan (≈ 0.05) y dist_centro_km, la variable numérica más importante, lo que confirma la utilidad de la variable creada.

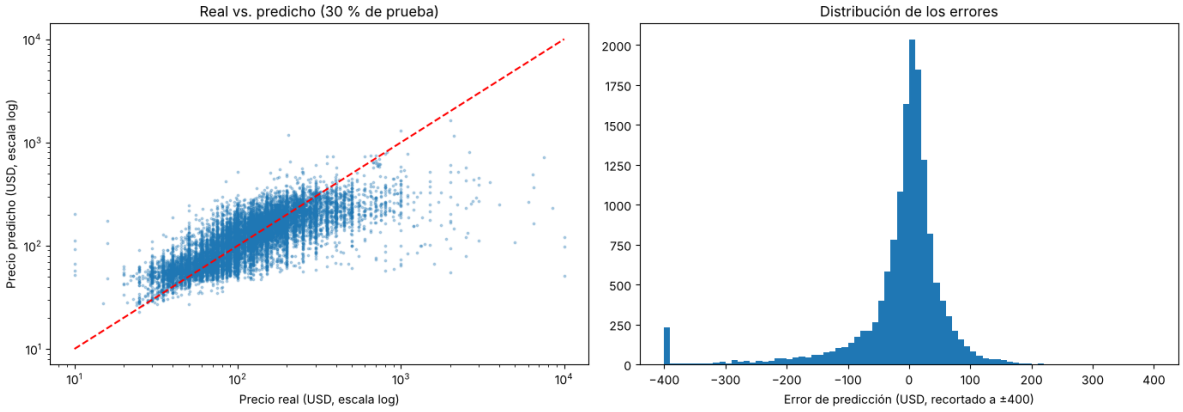


Figura 4. Precio real vs. predicho y distribución de los errores en el 30 % de prueba

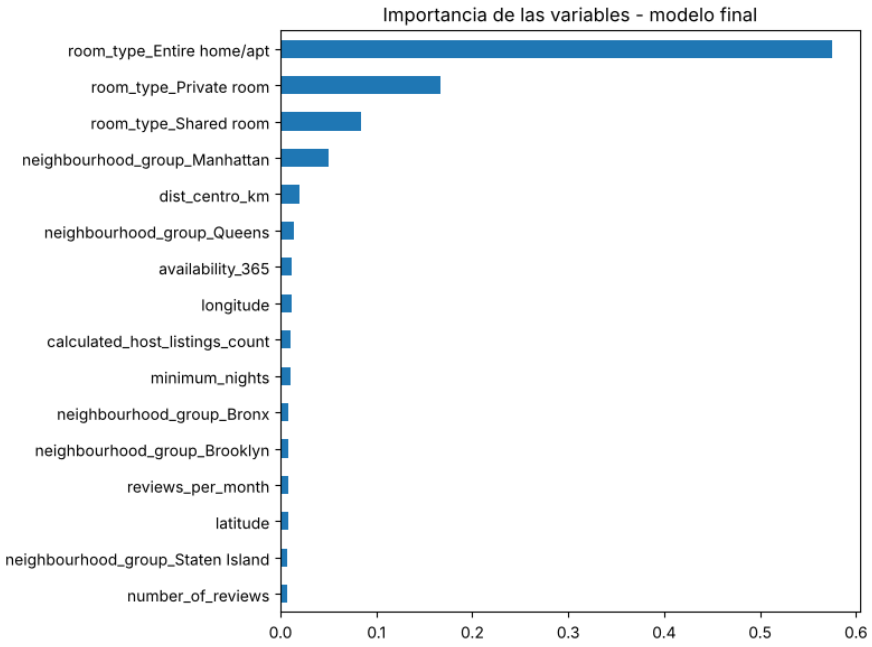


Figura 5. Importancia de las variables en el modelo final (XGBoost)

5. DESPLIEGUE

5.1 PREDICCIÓN DE DATOS FUTUROS: Crear interfaz para usar el modelo

El modelo final se almacenó con joblib en un **pipeline** (modelo_final_airbnb.pkl) que incluye todas las operaciones de preparación de los datos:

Tabla 7. Pasos del pipeline final

Paso	Clase	Operación
1. Preparación de datos	FunctionTransformer (preparar_datos)	Selecciona las 9 variables del modelo (descarta id, name, host_id, host_name, neighbourhood y last_review), imputa reviews_per_month vacío con 0 y aplica las reglas de calidad (minimum_nights entre 1 y 365, availability_365 entre 0 y 365)
2. Ingeniería de características	FunctionTransformer (crear_variables)	Crea dist_centro_km y aplica log(1 + x) a los conteos sesgados
3. Transformación	ColumnTransformer	Estandariza las variables numéricas y codifica con one-hot las categóricas
4. Modelo	XGBRegressor	Modelo final optimizado
5. Transformación del objetivo	TransformedTargetRegressor	Entrena con log(1 + price) y devuelve la predicción en dólares

Las funciones de los pasos 1 y 2 (preparar_datos y crear_variables) están en el archivo features.py, necesario para cargar el modelo. En el notebook de modelado se **comprobó** que el pipeline guardado se carga y da exactamente las mismas predicciones que el modelo en memoria en el 30 % de prueba (MAE = 56.92 USD), y que recibe registros con el formato del archivo original (con

identificadores, nombres, reviews_per_month vacío y 1 000 noches mínimas) y los prepara por sí mismo antes de predecir.

La interfaz se construyó con **Streamlit** (notebook Despliegue_Airbnb_NYC) y se publica en **Streamlit Community Cloud** a partir de un repositorio de GitHub que contiene app.py, features.py, modelo_final_airbnb.pkl, ubicaciones_distritos.csv y requirements.txt. El usuario marca la ubicación del alojamiento con un clic en un mapa interactivo (folium y streamlit-folium) y la aplicación asigna el distrito automáticamente: toma el distrito del alojamiento del dataset más cercano al punto marcado (método que acierta en el 99.97 % de los casos). Luego el usuario elige el tipo de alojamiento, ingresa las noches mínimas, la disponibilidad, las reseñas y el número de anuncios del anfitrión, y obtiene el precio estimado por noche.

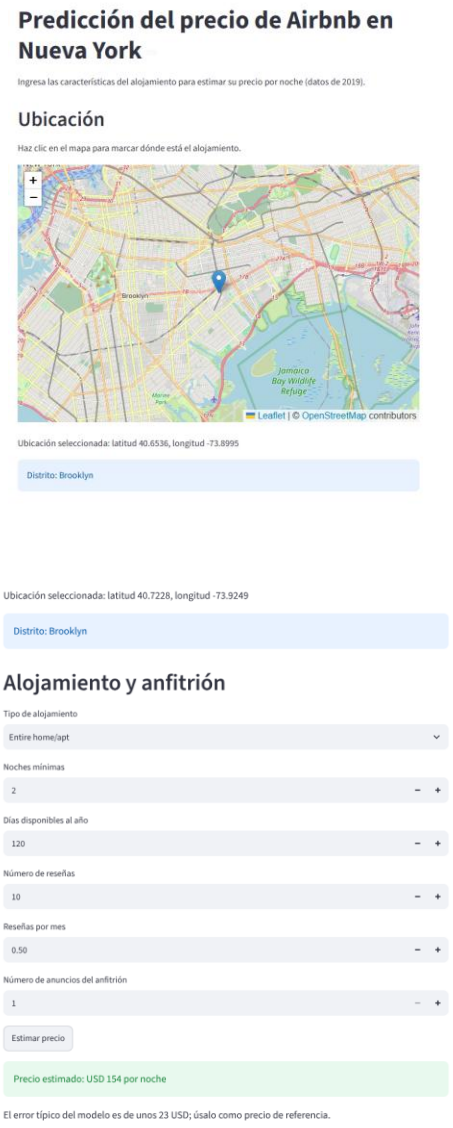


Figura 6. Interfaz gráfica de la aplicación: ubicación seleccionada en el mapa, formulario y precio estimado

5.2 MONITOREO: Definir tiempo de monitoreo

El modelo se entrenó con datos de 2019, y los precios cambian con el tiempo (inflación, temporada, regulación del alquiler de corta estancia). Antes de usarlo en producción debe reentrenarse con una extracción reciente de Inside Airbnb. Una vez en uso, se propone el siguiente monitoreo:

- **Frecuencia:** mensual durante los primeros 6 meses y trimestral después, comparando las predicciones con los precios reales de una nueva extracción de datos.
- **Medidas de desempeño:** MAE, MedAE y MAPE sobre los anuncios nuevos. **Umbral de alerta:** MAE mayor que 64 USD o MedAE mayor que 27 USD (un deterioro de alrededor del 15 % respecto a la evaluación actual).
- **Deriva de los datos:** cambios en la mediana del precio, en la proporción de tipos de alojamiento y de distritos, y aparición de valores fuera de las reglas de calidad.

5.3 CRONOGRAMA DE MANTENIMIENTO

Tabla 8. Cronograma de mantenimiento

Actividad	Frecuencia	Descripción
Monitoreo del desempeño	Mensual (6 meses), luego trimestral	Calcular MAE, MedAE y MAPE con datos nuevos y compararlos con los umbrales
Revisión de deriva de datos	Mensual	Comparar distribuciones de precio, tipo de alojamiento y distrito con las del entrenamiento
Actualización de datos y reentrenamiento	Trimestral o al superar un umbral	Nueva extracción de Inside Airbnb, preparación de datos y reentrenamiento del pipeline final
Reselección completa de modelos	Anual	Repetir validación cruzada, ANOVA/Tukey e hiperparametrización con los 7 modelos
Mantenimiento de la aplicación	Semestral	Actualizar librerías (scikit-learn, XGBoost, Streamlit) y verificar que el modelo carga y predice correctamente